



Кафедра
инженерной
кибернетики

НИТУ МИСИС
ИТКН
Кафедра инженерной кибернетики



Выпускная квалификационная работа

Система анализа производительности пространственных индексов в задаче геопоиска

Выполнил:

ст. группы БПМ-21-3 Ибрагимов П. И.

Научный руководитель:

старший преподаватель Тагиев Э.Р.

Москва

Актуальность

Картографические сервисы

IoT


Кикшеринг

Каршеринг

Экологические
датчики

Общественный
транспорт

Gamedev



Актуальность


Индекс - структура, создаваемая с целью повышения производительности поиска данных.

Примеры:

Python: **dict**

Java, c++,
go, rust: **map**

СУБД: **index**



Содержательная постановка задачи

Целью данной работы является разработка системы для анализа пространственных индексов, а также доработка и разработка новых индексов. Данная система должна представлять собой комплекс программного обеспечения, который должен уметь анализировать предложенные пространственные индексы: R-tree, R*-tree, KD-tree, GeoB-tree, H3B-tree и другие.

Анализ должен проводиться в разрезе трех операций:

а) Insert(p Point) - вставка новой точки p в индекс;

б) KNN(p Point, k int) Points - поиск множества точек S размера k , находящихся на наименьшем расстоянии от точки p ;

в) BBox(bottomLeft Point, upperRight Point) Points — поиск множества точек S , которые входят в прямоугольник, определяющийся левым нижним углом (bottomLeft) и правым верхним углом (upperRight).

Содержательная постановка задачи

Для решения поставленных целей необходимо решить следующие задачи:

- а) изучить существующие пространственные индексы;
- б) разработать программное обеспечение для тестирования пространственных индексов;
- в) реализовать в программном коде уже существующие индексы;
- г) доработать существующие индексы и разработать новые;
- д) протестировать и отладить разработанное программное обеспечение;
- е) проанализировать результаты работы программного обеспечения.

Найти наиболее подходящие структуры под анализируемые задачи.

Математическая постановка задачи

Пусть G - это множество всех точек в индексе, и каждая точка обозначается символом G_i , где $i \in \mathbb{N}$; Широта и долгота каждой точки обозначается как X_i и Y_i , где $X_i \in \mathbb{Q}$ и $Y_i \in \mathbb{Q}$.

Исследуемые операции:

а) $\text{Insert}(p \text{ Point})$ - вставка новой точки p в индекс;

б) $\text{KNN}(p \text{ Point}, k \text{ int}) \text{ Points}$ - поиск множества точек S . $S = \{G_i | G_i \in G, \text{dist}(p, G_i) \leq \text{dist}(p, G_j), \forall G_j \in G, G_j \notin S, |S| = k\}$, где dist - функция расстояния между двумя точками;

в) $\text{VBox}(\text{bottomLeft Point}, \text{upperRight Point}) \text{ Points}$ — поиск множества точек S . $S = \{G_i | G_i \in G, X_i \geq X_{\text{bottomLeft}}, Y_i \geq Y_{\text{bottomLeft}},$

$X_i \leq X_{\text{upperRight}}, Y_i \leq Y_{\text{upperRight}}\}$.

Дано:

а) $n \in \mathbb{N}$, n - количество элементов в индексе, в данном случае точек;


б) $f(n) = x$, $x \in \mathbb{Q}$, $x > 0$, где $f(n)$ - время выполнения операции в микросекундах.

Для каждой выше указанной операции и для каждой тестируемой структуры требуется вычислить сложность алгоритма.

$$f_{ax}(n) = O(f(n)).$$

А именно: реализуемое программное обеспечение должно уметь находить $f(n)$ для заданных n и строить график зависимости $f(n)$ от n . Разработанные и доработанные индексы должны корректно решать поставленные задачи.

Функциональная схема системы



Форма визуализации

[Чарты](#) [Визуализация](#)

Визуализация

Индексы

- ☐ K-d-дерево (kdtree)
- ☐ R-дерево Tidwal (rtree_tidwal)
- ☐ Перебор (bruteforce)
- ☒ GeoB-дерево 6 (geobtree_6)
- ☐ H3B-дерево 8 (h3btree_8)
- ☐ GeoBR-дерево 7 (geobtree_7)

Генераторы

- ☐ Простой генератор (simple_generator)
- ☒ Кластный генератор (cluster_generator)

Кол-во точек:

10 000

Соседи (N):

1 000

Радиус (m):


1 000

Загрузить данные

Найти ближайших соседей

Найти в квадрате

Выбранная точка: 55.7535, 37.5054



Форма тестирования

Индексы

- ☒ К-d-дерево
- ☒ R-дерево Tidwal
- ☐ Перебор
- ☐ GeoV-дерево 6
- ☒ H3B-дерево 8
- ☐ GeoBR-дерево 7

Задачи

- ☒ КНН 25%
- ☒ КНН 90%
- ☐ КНН 1%
- ☐ КНН 10
- ☒ КНН 100
- ☐ BBox 100
- ☒ BBox 2km
- ☐ Вставка

Start

10 000

End

1 000 000

Step

100




Created at: 02.06.2025, 00:46:44

Completed at: 02.06.2025, 03:43:06 (10582.4s)


Points range: 10000 - 100000

Step: 1000




Результаты тестирования №1

Задача: knn_90_p




GeoB-tree



1. Решение **VBox**



2. Решение **KNN**



Результаты тестирования №2



Выводы

R-tree

Самый популярный,
полный по методам и
в общем случае
быстрый

GeoB-tree

(и другие индексы на
B-tree)

Позволяют
кластеризировать

Метрика

(гаверсинус, геодезия,
евклид)

Влияет на точность,
но, зачастую, для
конечного
потребителя это не
важно.


Перебор

Зачастую показывает
результаты, сравнимые
с индексами-
фаворитами


Заключение

- Проведен анализ предметной области;
- Сформулированы содержательная и математическая постановки задачи;
- Разработано и протестировано алгоритмическое и программное обеспечение, полностью выполняющее поставленную задачу;
- Основные результаты работы были опубликованы в сборнике тезисов конференции «79-е Дни науки Университета МИСИС»;
- Работа была представлена на научной конференции кафедры Инженерной кибернетики «79-е Дни науки Университета МИСИС» и заняла третье место.

Приложение 1. Geohash





Geohash level-1





Geohash level-2

Приложение 2. KD-Tree




Приложение 3. R-Tree




Приложение 4. Тестирование VBox 100 точек


Задача: vbox_100



Приложение 5. Тестирование KNN 10 точек



Приложение 6. Тестирование KNN 1% точек



Приложение 7. Тестирование Insert

Задача: insert

